Clasificación binaria de `Disease_Risk` en RFMiD: preprocesado letterbox, ensembles con TTA y umbrales orientados a recall

Xabat Arin

Resumen

El cribado automático de enfermedad retiniana exige minimizar falsos negativos (FN) bajo desbalance de clases. Este trabajo describe un pipeline de clasificación binaria sobre el dataset RFMiD (`Disease_Risk`), con datos en el directorio padre `Retina/` y código en `retina_clasificacion/`. El preprocesado principal conserva la proporción de aspecto mediante *letterbox* (sin recorte aleatorio) a resolución 224×224. Se entrenan redes convolucionales (ResNet-152 con hiperparámetros Optuna; zoo con ResNet-50, DenseNet-121, EfficientNet-B0 y ConvNeXt-Tiny) con Focal Loss, y en una etapa posterior fine-tuning orientado a recall (reponderación de ejemplos difíciles y α de Focal centrada en positivos). La inferencia combina Test-Time Augmentation (identidad, volteo horizontal y rotaciones $\pm 10°$) y promedios de ensemble. Los umbrales se eligen *solo en validación* (índice de Youden, recall de validación $\geq 0{,}91$, o regla operativa FN $<$ FP con bootstrap al 90 %); el test se usa únicamente para informe final, con intervalos de confianza bootstrap al 95 %. El sistema de referencia clínica del proyecto (FINAL 05: ensemble 4× ResNet-152 + TTA, umbral recall $\geq 0{,}91$) obtiene en test recall 0,929, especificidad 0,881, F1 0,948, AUC 0,971 y matriz FN 36 / FP 16. Bajo la regla FN $<$ FP, el ensemble zoo + ResNet-152 recall-focus mejora el recall a 0,957 (FN 22 / FP 25) con F1 0,954. Los resultados son experimentales y no constituyen validación como dispositivo médico.

Palabras clave: RFMiD, `Disease_Risk`, clasificación binaria, Focal Loss, Test-Time Augmentation, ensemble, umbral de decisión, bootstrap, Grad-CAM.

1. Introducción

Las retinopatías y otras patologías del fondo de ojo son causa relevante de pérdida visual prevenible si se detectan a tiempo. Datasets públicos como RFMiD permiten entrenar clasificadores que, a partir de una fotografía de retina, estimen el riesgo binario de enfermedad (`Disease_Risk`). En cribado, el coste de un falso negativo (caso enfermo etiquetado como sano) suele ser mayor que el de un falso positivo, y el desbalance hacia la clase positiva complica la optimización directa por accuracy.

Este proyecto aborda tres objetivos prácticos: (i) establecer un baseline robusto ResNet-152 con preprocesado letterbox e hiperparámetros Optuna [Akiba et al., 2019]; (ii) elevar el recall mediante ensembles, TTA [Wang et al., 2019, Shorten and Khoshgoftaar, 2019] y umbrales seleccionados en validación sin fuga al test; y (iii) explorar un zoo de arquitecturas y un fine-tuning recall-focus, manteniendo caídas acotadas de accuracy, F1 y AUC respecto al sistema de referencia. La selección de modelos no se reduce a accuracy: se priorizan recall alto, la regla operativa FN $<$ FP en validación y, en comparaciones individuales, métricas de ranking (AUC) y equilibrio (F1, Youden).

2. Metodología

2.1. Datos y particiones

Se utiliza RFMiD en clasificación binaria. Los CSV e imágenes residen en `DATA_ROOT` (directorio padre `Retina/`); el código y los artefactos viven en `retina_clasificacion/`. El notebook de datos construye DataFrames train/val/test con `image_path` y `disease_risk`. En las evaluaciones reportadas, validación y test comprenden 640 imágenes cada uno (p. ej. TN+FP+FN+TP = 640). Todo ajuste de época, Optuna, miembros de ensemble, TTA y umbral se realiza en train/validación; el test solo se usa en el informe

final.

2.2. Preprocesado

La ruta principal (*nocrop*) aplica letterbox: redimensionado conservando la proporción y relleno negro hasta un cuadrado de 224×224, idéntico en train y evaluación. Experimentos históricos con `RandomResizedCrop` se conservan como miembros del ensemble de referencia, pero el entrenamiento reciente prioriza letterbox.

2.3. Arquitecturas y entrenamiento

El baseline es ResNet-152 ImageNet, reentrenado con hiperparámetros Optuna (TPE) y Focal Loss [Lin et al., 2017] ($\gamma = 2$, α ajustable). El notebook de mejora de recall construye un ensemble de cuatro checkpoints ResNet-152 (ajustado/baseline $\times$ letterbox/crop). El fine-tuning recall-focus (warm-start desde Optuna letterbox) explora variantes con reponderación por dificultad [Shrivastava et al., 2016] y α de Focal orientada a positivos; la selección de checkpoint usa especificidad bajo la restricción FN $<$ FP en validación. El zoo (ResNet-50, DenseNet-121, EfficientNet-B0, ConvNeXt-Tiny) sigue la receta recall-focus sin Optuna por arquitectura.

2.4. Inferencia, umbrales y evaluación

La TTA promedia cuatro vistas: identidad, volteo horizontal y rotaciones $\pm 10°$ [Wang et al., 2019, Shorten and Khoshgoftaar, 2019]. Los ensembles promedian probabilidades TTA entre miembros [Dietterich, 2000]. Umbrales:

- **Youden** en validación [Youden, 1950] (comparaciones individuales);
- **recall de validación** $\geq 0{,}91$ (margen 0,01 sobre un objetivo 0,90);
- **FN** $<$ **FP** con bootstrap al 90 % en validación (regla operativa).

Las métricas de test incluyen IC al 95 % con 1000 remuestreos bootstrap y semilla 42 [Efron and Tibshirani, 1993].

2.5. Explicabilidad cualitativa (Grad-CAM)

Grad-CAM [Selvaraju et al., 2017] genera mapas de activación a partir de los gradientes de la clase predicha respecto a un mapa de características convolucional (en ResNet, la última unidad de `layer4`). Se aplica sobre checkpoints individuales—no sobre el promedio del ensemble FINAL 05, que no admite un Grad-CAM único de forma natural—y sobre un conjunto fijo de imágenes de test: los ejemplos más confiados de cada grupo TP/TN/FP/FN según el ResNet-152 baseline (umbral 0,5). El objetivo es ilustrar *dónde* atienden los modelos al clasificar riesgo, no sustituir criterios clínicos ni seleccionar arquitectura, umbral o checkpoint. Los mapas se interpretan con cautela: resaltan regiones correlacionadas con la decisión del modelo, sin garantizar correspondencia uno a uno con lesiones diagnósticas.

3. Resultados

La Tabla 1 resume el mejor modelo de cada categoría en test.

Tabla 1: Mejores configuraciones por categoría en **test**. Reglas: (1) baseline ResNet-152 Optuna letterbox, Youden; (2) mejor zoo Youden por F1 (ResNet-50); (3) mejor individual + TTA bajo FN $<$ FP por F1 (DenseNet-121); (4) referencia FINAL 05 (ensemble 4$\times$ ResNet-152 + TTA, recall val $\geq 0{,}91$); (5) mejor ensemble + TTA bajo FN $<$ FP (zoo + ResNet-152 recall-focus).

Modelo / configuración	Umbral	AUC	Rec.	Esp.	Prec.	F1	FN	FP
(1) RN-152 Optuna, Youden	0,545	0,968	0,850	0,963	0,989	0,914	76	5
(2) ResNet-50 zoo, Youden	0,572	0,950	0,875	0,910	0,974	0,922	63	12
(3) DenseNet-121+TTA, FN<FP	0,380	0,967	0,951	0,806	0,949	0,950	25	26
(4) FINAL 05 4×RN-152+TTA	0,399	0,971	0,929	0,881	0,967	0,948	36	16
(5) Zoo+RN-152 RF+TTA, FN<FP	0,448	0,973	0,957	0,813	0,951	0,954	22	25

Notación: RN-152 = ResNet-152; RF = recall-focus (variante control seleccionada en validación). Métricas redondeadas a tres decimales a partir de un CSV con todos los modelos entrenados. No se listan las 62 filas del CSV consolidado.

El baseline Youden (fila 1) alcanza AUC alta y pocos FP, pero el recall (0,850) deja 76 FN en test. El mejor zoo bajo Youden (fila 2, ResNet-50 por F1) mejora recall y F1 a costa de más FP. DenseNet-121 con TTA (fila 3), umbral bajo FN $<$ FP en validación, reduce FN a 25 y mantiene FN $<$ FP también en test, con AUC 0,967.

El sistema de referencia FINAL 05 (fila 4) usa umbral recall de validación $\geq$ 0,91, no la regla FN $<$ FP. En test ofrece un equilibrio entre recall 0,929 y especificidad 0,881 (FN 36 / FP 16; FN $>$ FP es compatible con esa regla), con IC 95 % de recall aproximadamente [0,906, 0,951] y AUC [0,958, 0,981]. En cambio, bajo la regla FN $<$ FP, el ensemble de cuatro modelos del zoo más ResNet-152 recall-focus (fila 5) obtiene el mejor recall (0,957) y F1 (0,954) de la tabla, con FN 22 / FP 25; la especificidad desciende respecto a FINAL 05. En el notebook recall-focus previo, el ensemble elegido también reduce FN frente a FINAL 05 (p. ej. FN 28 / FP 22), aunque la condición FN $<$ FP se cumple en validación y no siempre en test.

En conjunto, FINAL 05 permanece la referencia cuando se prioriza especificidad bajo umbral recall $\geq$ 0,91; el ensemble zoo+recall-focus (fila 5) es preferible cuando el objetivo operativo es maximizar recall bajo FN $<$ FP fijado en validación.

3.1. Mapas Grad-CAM: ResNet-152 de referencia vs. recall-focus

La Figura 1 compara, sobre las mismas imágenes TP de test, el ResNet-152 letterbox Optuna de partida (`best_resnet152_disease_risk_optuna_nocrop.pt`, miembro del linaje FINAL 05) con la variante recall-focus control seleccionada en validación. En verdaderos positivos ambos modelos concentran activación sobre regiones internas del disco retiniano; en casos con lesiones claras (p. ej. exudados visibles) los mapas coinciden en gran medida. Las diferencias suelen ser de extensión o intensidad del foco, no de un cambio radical de región atendida.

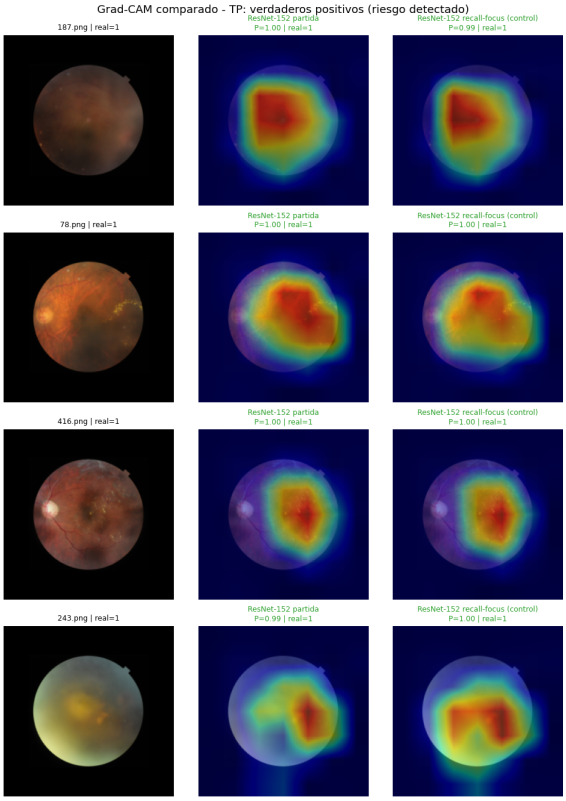


Figura 1: Grad-CAM en verdaderos positivos (mismas imágenes de `selected_images.json`). Columnas: original, ResNet-152 de partida (Optuna letterbox) y ResNet-152 recall-focus (control). Texto en verde: acierto respecto al umbral FN $<$ FP de validación de cada modelo. Grad-CAM por checkpoint individual; no es el ensemble FINAL 05.

La Figura 2 muestra falsos negativos del mismo par de modelos. Aquí aparecen más discrepancias: a veces la activación se desplaza hacia el borde de la imagen o hacia estructuras anatómicas frecuentes (p. ej. disco óptico), y las probabilidades de riesgo permanecen bajas. El fine-tuning recall-focus no garantiza mapas "más clínicos"; solo altera, de forma cualitativa, el patrón de activación y la confianza en algunos casos.

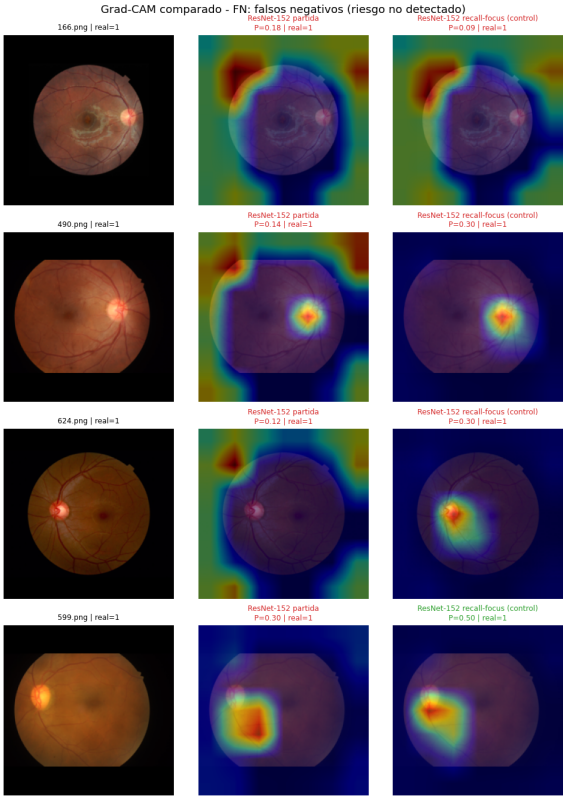


Figura 2: Grad-CAM en falsos negativos (mismas imágenes seleccionadas). Misma disposición que en la Figura 1. Los mapas ilustran atención del modelo sobre regiones de la retina o del marco de la imagen; no se interpretan como localización diagnóstica validada.

La Figura 3 amplía la comparación a arquitecturas del zoo (mismas imágenes TP): ResNet-152 Optuna letterbox de referencia frente a ResNet-50, DenseNet-121, EfficientNet-B0 y ConvNeXt-Tiny. A igualdad de etiqueta correcta, los mapas no son idénticos—unos focos son más localizados y otros más difusos—, lo que sugiere diversidad de representaciones útil para ensembles, sin atribuir a cada hotspot un significado clínico inequívoco.

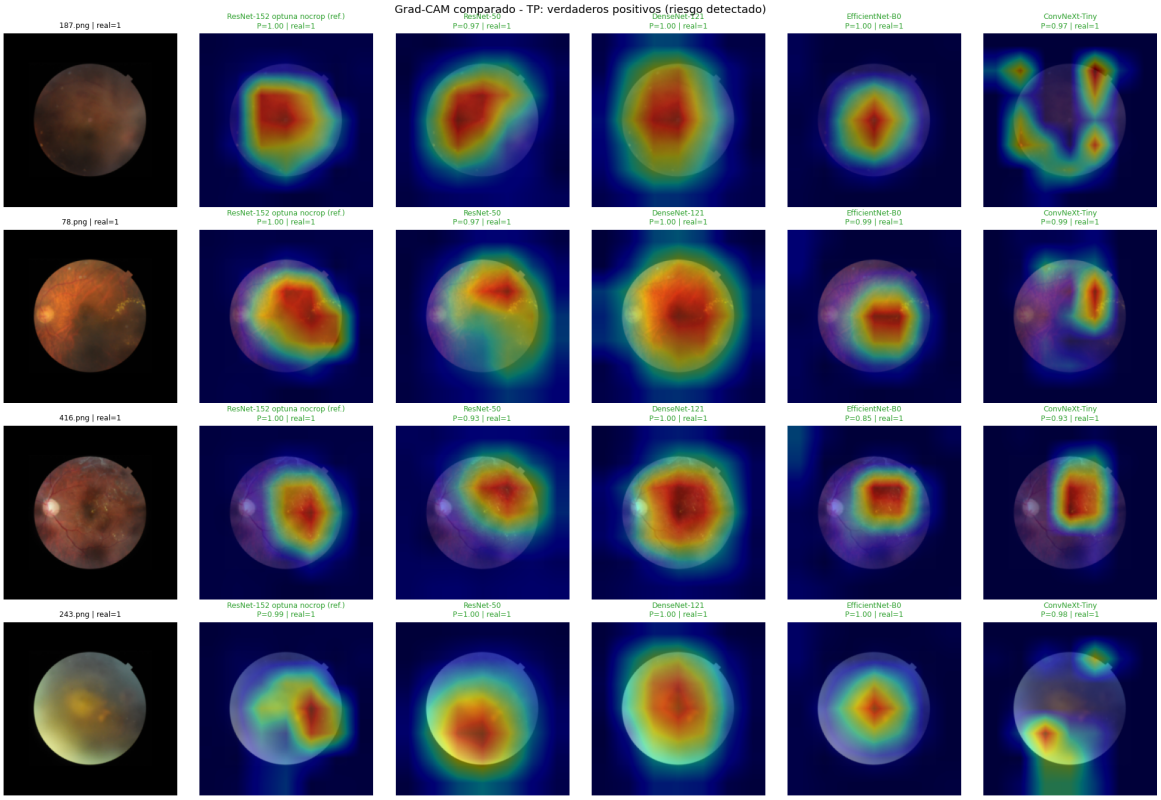


Figura 3: Grad-CAM multi-arquitectura en verdaderos positivos (mismas imágenes de `selected_images.json`). Columna de referencia: ResNet-152 Optuna letterbox (`best_resnet152_disease_risk_optuna_nocrop.pt`); resto: zoo recall-focus letterbox. Umbral Youden de validación por modelo.

4. Conclusión

Se ha documentado un pipeline reproducible para `Disease_Risk` en RFMiD con letterbox, Focal Loss, Optuna, TTA, ensembles y umbrales elegidos solo en validación. El ensemble FINAL 05 ofrece un compromiso clínico de referencia (FN 36 / FP 16); el ensemble zoo + ResNet-152 recall-focus mejora el recall bajo la regla FN $<$ FP. Los resultados dependen del split y de las reglas de umbral; no implican aptitud como dispositivo médico ni sustituyen validación clínica externa.

Referencias

Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.

Thomas G. Dietterich. Ensemble methods in machine learning. In *Multiple Classifier Systems*, pages 1–15. Springer, 2000. doi: 10.1007/3-540-45014-9_1.

Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017. doi: 10.1109/ICCV.2017.324.

Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017. doi: 10.1109/ICCV.2017.74.

Connor Shorten and Taghi M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1):60, 2019. doi: 10.1186/s40537-019-0197-0.

Abhinav Shrivastava, Abhinav Gupta, and Ross Girshick. Training region-based object detectors with online hard example mining. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 761–769, 2016. doi: 10.1109/CVPR.2016.89.

T.-C. Wang, Y.-Y. Liu, Y.-H. Tsai, Y.-R. Yeh, and Y.-C. F. Wang. Test-time augmentation for deep learning-based cell segmentation. In *Proceedings of the IEEE International Symposium on Biomedical Imaging (ISBI)*, pages 1544–1548, 2019. doi: 10.1109/ISBI.2019.8759152.

W. J. Youden. Index for rating diagnostic tests. *Cancer*, 3(1):32–35, 1950. doi: 10.1002/1097-0142(1950)3:1<32::AID-CNCR2820030106>3.0.CO;2-3.